

תרגיל בית 3 - תהליכי החלטה מרקוביים ולמידה מחיזוקים

מבוא לבינה מלאכותית (236501) | סמסטר אביב 2026

דוח הגשה מרכזי ומאוחד (חלק יבש + חלק רטוב)

חלק א' - חלק יבש (45 נקודות)

שאלה 1: ייצוג מצבים ותכונות מרקוב (6 נק')

- a. המשימה (הצלחה), ואינו מציין את רמת הסוללה או הזמן הנותר, המכתיבים את ההיתכנות של מסלולים שונים (row, col) המיקום לבדו. ההיסטוריה הדרושה לקבלת החלטות. למשל, המיקום בלבד אינו מציין האם הרובוט כבר אוסף חיישן (מה שקובע אם הגעה ליציאה תסיים את אינו מקיים את תכונת מרקוב מכיוון שאינו מכיל את כל
- b. State = (row, col, carrying_sensor, battery_level, time_remaining): ייצוג המצב המורחב המקיים את תכונת מרקוב הינו.
- c. המצבים המורחבים: 22 מיקומים $\times$ 2 מצבי נשיאה (כן/לא) $\times$ 6 רמות סוללה (0-5) $\times$ 21 רמות זמן (0-20) = 5,544 מצבים אפשריים. חישוב חסם עליון למספר
- d. ברגע שהרובוט מגיע ל carrying_sensor=False, P, דוגמה למצב הנספר בחסם אך אינו ישים: מצב שבו המיקום הוא משבצת האיסוף. ללא החיישן P-החיישן נאסף באופן מיידי, ולכן לא ייתכן שהרובוט ימצא ב P-עם זמן נותר שאינו התחלתי. על פי הגדרת הסביבה,

שאלה 2: משוואות בלמן לאופק סופי (6 נק')

a. $t \geq 1$: המשוואה הרקורסיבית עבור s. לכל מצב $V_0(s) = 0$: תנאי הבסיס לאופק.

$$V_t(s) = \max_{a \in A(s)} \sum_{s'} P(s' | s, a) [R(s, a, s') + V_{t-1}(s')], \quad V_0(s) = 0$$

b. 1 עם תגמול 0, כך שמצבים סופיים אינם מניבים תגמולים נוספים, לכל t, $V_t(s) = 0$ -הערך נקבע ל s, טיפול במצבים סופיים: במצב סופי. וההסתברות להישאר בו היא

c. המדיניות האופטימלית התלויה בזמן הינה:

$$\pi_t^*(s) = \arg \max_{a \in A(s)} \sum_{s'} P(s' | s, a) [R(s, a, s') + V_{t-1}(s')]$$

d. הפעולות. ככל ש t כמות הצעדים הנותרת, s המדיניות האופטימלית באופק סופי אינה חייבת להיות סטציונרית מכיוון שבעבור אותו מצב. קטן יותר, הרובוט עשוי לבחור בפעולות חמדניות יותר כדי להגיע ליעד לפני תום הזמן t-משפיעה ישירות על כדאיות

שאלה 3: מדיניות סטציונרית מול לא-סטציונרית (6 נק')

a. RISKY: הינה 2-. תועלת צפויה עבור SAFE צעדים נותרים: תועלת צפויה עבור t=2 עבור.

$$\mathbb{E}[U(\text{RISKY})] = 0.7 \cdot (20 - 2) + 0.3 \cdot (-20 - 2) = 12.6 - 6.6 = 6.0$$

לכן הפעולה RISKY עדיפה עבור t=2.

b. צעדים נותרים t=4 עבור.

$$\mathbb{E}[U(\text{SAFE}, t=4)] = 1.0 \cdot (20 - 4) = 16.0 > 6.0$$

לכן הפעולה SAFE עדיפה עבור t=4.

c. SAFE לעומת t=2 ל-RISKY) בלבד אינו מייצג את המצב באופן מלא מכיוון שהפעולה האופטימלית משתנה כתלות בזמן הנותר J המיקום.

מדיניות סטציונרית התלויה במיקום בלבד אינה יכולה לייצג את שתי ההחלטות השונות. $t=4$ -ל

שאלה 4: הערכת מודל מעבר מדגמים (5 נק')

אומדן Laplace עבור הסתברויות מעבר:

$$\hat{P}(s' | s, a) = \frac{N(s, a, s') + \lambda}{N(s, a) + \lambda K}$$

a. $P_{\text{hat}}(u | s, \text{UP}) = (6 + 1) / (8 + 4 \cdot 1) = 7/12$. $P_{\text{hat}}(r | s, \text{UP}) = (2 + 1) / 12 = 3/12$. $P_{\text{hat}}(d | s, \text{UP}) = P_{\text{hat}}(s | s, \text{UP}) = 1/12$.

b. $P_{\text{hat}}(r | s, \text{RIGHT}) = (1 + 1) / (2 + 4 \cdot 1) = 2/6$. $P_{\text{hat}}(d | s, \text{RIGHT}) = (1 + 1) / 6 = 2/6$. $P_{\text{hat}}(s | s, \text{RIGHT}) = P_{\text{hat}}(u | s, \text{RIGHT}) = 1/6$.

c. לא נצפו תצפיות כלל, ולכן ההחלטה מקצה הסתברות אחידה $1/4$ לכל מצב, מה שמייצר מודל מעבר לא אמין WAIT עבור הפעולה.

d. בעוד למידה ללא מודל (כמו $P_{\text{hat}}, R_{\text{hat}}$) משתמשת בתצפיות כדי לבנות מודל מעבר ותגמול מפורש (ADP) 'גישת' הערך מודל ואז תכנן. מעדכנת ערכי פעולה ישירות מהדגמים ללא בניית מודל מפורש (Q-learning) ומתכננת בתוכו,

שאלה 5: תגמולים ומדיניות אופטימלית (5 נק')

a. לשנות את המדיניות האופטימלית ולהפוך אותה לזהירה יותר, כך שהסוכן ימנע ממסלולים העוברים ליד סכנה אף אם הם קצרים יותר. הגדלת הקנס בתאי סכנה (מ-50 ל-200) עשויה

b. אינה משנה את המדיניות האופטימלית מכיוון שסדר העדיפויות בין כל המסלולים נשמר בדיוק $c > 0$ הכפלת כל התגמולים בסקלר חיובי.

c. הוספת קבוע שלילי (למשל -1) לכל צעד מעודדת מסלולים קצרים יותר ומפחיתה שוטטות, מכיוון שכל צעד נוסף כרוך בעונש נוסף.

d. עשויה להיות נמוכה בגלל עונש כבד במקרה של כישלון, אך אם הסתברות ההצלחה גבוהה מאוד, בפועל רוב הסימולציות יסתיימו בהצלחה. תוחלת התועלת במסלול מסוכן

שאלה 6: עדכון הפרש זמני (TD) ו-Q-learning (6 נק')

a. $V(s)$ עבור TD(0) נוסחת עדכון:

$$V(s) \leftarrow V(s) + \alpha[r + \gamma V(s') - V(s)]$$

$$V_{\text{new}}(s) = 4 + 0.25 \cdot (-2 + 0.9 \cdot 7 - 4) = 4.075$$

b. $Q(s, a)$ עבור Q-learning נוסחת עדכון:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

$$Q_{\text{new}}(s, a) = 1 + 0.2 \cdot (5 + 0.8 \cdot 3 - 1) = 2.28$$

c. לומד את ערך המדיניות האופטימלית Q-learning בעוד (On-policy value prediction), מעריך את ערך המדיניות הנוכחית TD(0) (Off-policy control).

d. epsilon-greedy הסתברות לבחירת פעולה שאינה חמדנית ב.

$$P(a \text{ non-greedy}) = \frac{\epsilon}{|A(s)|} = \frac{0.1}{5} = 0.02$$

e. החקירה מוקדם מדי, והסוכן עלול להתכנס למדיניות תת-אופטימלית שנתקעה במסלול הראשון שמצא epsilon דעיכה מהירה מדי של. תגרום להפסקת

שאלה 7: אומדן Monte Carlo, TD והטיית מדגם (5 נק')

a. עבור First-Visit Monte Carlo אומדן $V(s_0)$:

$$V_{MC}(s_0) = \frac{1}{N_{ep}} \sum_{i=1}^{N_{ep}} G_i = \frac{6+2+4}{3} = 4.0$$

- b. אחד בהסתמך על הערך המוערך של המצב הבא $TD(0)$ ממתין לסיום הפרק ומחשב את התגמול המצטבר הממשי, בעוד Monte Carlo (Bootstrapping) מעדכן מיד לאחר צעד.
- c. הסוכן עלול להחמיץ אותה, Q-learning-נצפתה לעיתים נדירות תגרום לאומדן לא מדויק של ערכה. ב הטיית מדגם שבה פעולה. אם פעולה אופטימלית לא נחקרה מספיק, מעודד חקירה טבעית של כל זוגות מצב-פעולה שלא נחקרו מספיק (Optimistic Initialization) Q אתחול אופטימי של ערכי.

שאלה 8: KNN, נרמול מאפיינים ועלות החלטה (6 נק')

a. מרחק אוקלידי:

$$d(x, q) = \sqrt{(x_1 - q_1)^2 + (x_2 - q_2)^2}$$

$d(x_1, q) = \sqrt{5} \approx 2.24$, $d(x_2, q) = \sqrt{8} \approx 2.83$, $d(x_3, q) = 30.0$, $d(x_4, q) = \sqrt{785} \approx 28.02$. השכן הקרוב ביותר הינו x_1 (normal). חישוב מרחקים:

b. Min-Max נרמול:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}}$$

גם לאחר נרמול, $d_{norm}(x_1, q) \approx 0.335$ הינו המינימלי, והסיווג נשאר normal.

c. (טווח 0-3 recent_slips (טווח 0-100 דומיננטי לחלוטין ומעלים את השפעת) smoke_density ללא נרמול, המאפיין.

d. גדול מחליקה את הגבול אך מושפעת מכיתות רוב K רגישה לרעש. בחירת $K=1$ קטן K בחירת.

e. המנחש תמיד את הכיתה הנפוצה ישיג דיוק גבוה אך ייכשל בזיהוי מקרים מסוכנים נדירים, (Imbalanced Data) בנתונים לא מאוזנים. מסווג.

חלק ב' - חלק רטוב: תכנון כאשר המודל ידוע (20 נקודות)

תוצאות תכנון דינמי לאופקים שונים (Finite-Horizon DP)

סופי על פי משוואות בלמן עבור $H \in \{12, 20, 30\}$. להלן ריכוז התוצאות והערכת המדיניות על 100 סימולציות ($\text{seed}=236501$):
הרצנו תכנון דינמי לאופק

אופק H	התחלתי $V(s_0)$	מצבים נגישים	תגמול ממוצע	שיעור הצלחה	אורך ממוצע	סוללה/סכנה
H=12	-30.729	237	-41.00	0.0%	6.00	B:100/D:0
H=20	-30.229	874	-27.50	15.0%	6.75	B:85/D:0
H=30	-30.223	1684	-41.00	0.0%	6.00	B:100/D:0

ניתוח התוצאות:

- עבור $H=12$: האופק קצר מדי מכדי לאפשר הגעה למשבצת האיסוף P והגעה חזרה ליציאה E במסלול בטוח, ולכן שיעור ההצלחה הינו 0.0%. מספיק להשלמת המשימה בהצלחה (15% הצלחה בסימולציה סטוכסטית מול 85% כשלוני סוללה עקב סטיות מקריות בתאים משובשים).
- עבור $H=20$: האופק כמות המצבים הנגישים גדלה ל-1,684. תוכנית DP מוצאת נתיבים ארוכים יותר הסוללה אוזלת ללא טעינה מחדש.
- עבור $H=30$:

ניתוח שינוי מדיניות לפי זמן וסוללה (Policy Slices)


הנותר והסוללה משתנים: עבור $t=20$ נבחרת הפעולה RIGHT (פנייה לכיוון עמדת הטעינה R), בעוד עבור $t \leq 19$ נבחרת הפעולה UP. מבחינת טבלת פרוסות המדיניות (Policy Slices), נצפה שינוי בפעולה הנבחרת עבור אותה משבצת פיזית (0, 0) כאשר הזמן

ניתוח הגדלת קנס תאי סכנה (Hazard Penalty Experiment)


הצלחה של 15.0% ותגמול ממוצע -27.50. המדיניות נשארה זהה מכיוון שהמתכנן האופטימלי ממילא נמנע מלהיכנס לתאי סכנה סופיים (X). בהכפלת קנס הסכנה ל-200 (פי 4 מהבסיס -50): תכנון DP הפיק ערך התחלתי $V(s_0) = -30.229$. בסימולציה נרשם שיעור

ויזואליזציה של פרוסות מדיניות (Policy Slices)

Policy slice: $t=15$, carrying=False, battery=1



Policy slice: $t=5$, carrying=True, battery=2



מימין: מדיניות עבור $t=5$ כאשר הסוכן נושא את החיישן עם סוללה 2. משמאל: מדיניות עבור $t=15$ ללא חיישן עם סוללה 1.

חלק ג' - חלק רטוב: למידה מחיזוקים (30 נקודות)

1. הערכת מודל מתוך דגמים אופליין (Model Estimation)

אומדן מעברים ותגמולים P_hat, R_hat מתוך קבצי הדגמים (Sparse vs Good Data) עם החלקת λ (Laplace ($\lambda \in \{0, 0.1, 1.0\}$):

סוג הדאטה	החלקה (λ)	מעברים שנלמדו	תגמול ממוצע	שיעור הצלחה
דל (Sparse)	$\lambda = 0.0$	69	-41.00	0.0%
דל (Sparse)	$\lambda = 0.1$	69	-41.00	0.0%
דל (Sparse)	$\lambda = 1.0$	69	-41.00	0.0%
כיסוי טוב (Good)	$\lambda = 0.0$	67	-28.45	14.0%
כיסוי טוב (Good)	$\lambda = 0.1$	67	-28.45	14.0%
כיסוי טוב (Good)	$\lambda = 1.0$	67	-28.45	14.0%

ב-E ושיעור ההצלחה הוא 0.0%. בדאטה הטוב (Good), המודל לומד את מעברי ההצלחה ומשיג 14.0% הצלחה (קרוב ל-15% Oracle). מסקנה: בדאטה הדל (Sparse) לא נצפו מסלולי הצלחה כלל, ולכן המודל הנלמד אינו מכיר את תגמול ההצלחה.

2. השוואת הערכת ערכים: First-Visit MC מול TD(0)

הערכת V^{π} עבור המדיניות הקבועה $H=20$ לאורך 400 פרקים:

מצב ($s = (r, c, s, b, t)$)	ערך אמת DP	ערך Monte Carlo	ערך TD(0)	שגיאת TD(0)
(0,0,0,6,20)	-30.229	-28.378	-22.150	8.0794
(0,0,0,5,19)	-40.000	-40.000	-39.997	0.0032
(0,0,0,4,18)	-39.000	-39.000	-39.000	0.0001
(0,0,0,3,17)	-38.000	-38.000	-38.000	0.0000
(0,0,0,2,16)	-37.000	-37.000	-37.000	0.0000

יותר ושונות קטנה יותר בהשוואה ל-Monte Carlo הודות לשימוש ב-Bootstrapped values, במיוחד במצבים מתקדמים לאורך המסלול. ניתוח: TD(0) מפגין שגיאה נמוכה.

3. חקירת Boltzmann (Softmax Action Selection)

נוסחת בחירת הפעולות ב-Boltzmann Softmax:

$$P(a | s) = \frac{\exp(Q(s, a)/T)}{\sum_{b \in A(s)} \exp(Q(s, b)/T)}$$

4. השוואה מרכזית בין סוכני ההחלטות (Decision Agents)

להלן טבלת ההשוואה המרכזית בין כל סוכני ההחלטה שנבדקו במטלה:

סוכן החלטה / אלגוריתם	תגמול ממוצע	שיעור הצלחה	אורך ממוצע	כישלונות סוללה
Oracle Planner (True DP $H=20$)	-27.50	15.0%	6.75	85
Estimated Model (Good Data, $\lambda=0.1$)	-28.45	14.0%	6.75	86
Estimated Model (Sparse Data, $\lambda=0.1$)	-41.00	0.0%	6.00	100
Q-learning (Constant Epsilon = 0.1)	-36.25	5.3%	6.32	142
Q-learning (Decaying Epsilon)	-41.00	0.0%	6.00	150
Boltzmann Exploration ($T = 0.2$)	-40.39	0.7%	6.02	149

150	6.00	0.0%	-41.00	Boltzmann Exploration ($T = 1.0$)
-----	------	------	--------	-------------------------------------

5. דיון בחקירה מול ניצול וסיווג אלגוריתמים

- Oracle Planner: (Model-based) מבוסס מודל (אינו לומד מדגמים, Oracle Planner: (Model-based) מבוסס מודל).
 - Estimated Model Planner: (Model-based) מבוסס מודל (אופליין / פסיבי (לומד מדאטה מוקלט, Estimated Model Planner: (Model-based) מבוסס מודל).
 - Q-learning: (Model-free) ללא מודל (Active / On-policy exploration, Off-policy update) Q-learning: (Model-free) ללא מודל).
- מכיוון שלא נצפה אות החיזוק החיובי של ההצלחה ב-E, הסוכן לומד להימנע מתנועה ומתכנס למסלולים קצרים המסתיימים בכשל סוללה.
- דיון בכישלון חקירה: בנתונים דלים (Sparse Data) או כאשר epsilon דועך מהר מדי, הסוכן סובל מכיסוי נתונים לקוי (Data Sparsity).

חלק ד' - הצהרת שימוש בכלי 5 AI (נקודות)

- במהלך העבודה על תרגיל בית 3 נעשה שימוש בסייען ה-AI האוטונומי (Antigravity AI Assistant).
- בחלק התאורטי (חלק א'): ניתוח ניסוח השאלות, וידוא חישובי מטריצות מעבר ונוסחאות בלמן, ואימות חישובי מרחק KNN ונרמול Min-Max.
- שימוש
- run_assignment_smoke.py, אימות הפונקציות ב-planning_rescue.py ו-learning_rescue.py, וריכוז הנתונים הסטטיסטיים.
- שימוש בחלק המעשי (חלקים ב' ו-ג'): כלי ה-AI שימש להרצת בדיקות היחידה (tests_public.py), הרצת תסריט הסימולציה
- קובץ PDF זה בוצעה באופן אוטומטי ומבוקר באמצעות סקריפט Python ייעודי שנכתב ע"י כלי ה-AI עם רנדור נוסחאות LaTeX ווקטוריות.
- הפקת הדוח: הפקת
- כל הפתרונות והקוד נבדקו, אושרו ואומתו באופן עצמאי על ידינו.