

שאלה 1

- a. מכיוון שהמיקום לבדו אינו מכיל את כל ההיסטוריה הדרושה להחלטה. למשל, המצב אינו מציין אם הרובוט נושא חיישן או לא, מה שיקבע אם הגעה ליציאה היא מעבר למצב סופי או לא. בנוסף, המצב אינו מציין גם את רמת הסוללה, דבר שמצריך מעקב אחרי היסטורית המצבים ולכן סותר את התנאי המרקובי.
- b. $State = (row, col, battery, carrying_sensor, time)$
- c. ישנם 22 מיקומים, בכל אחד מהם יכול להיות כל רמת סוללה, כל זמן נשאר וכל נשיאה או אי נשיאה של החיישן. סה"כ $22 \times 6 \times 21 \times 2 = 5544$.
- d. דוגמה למצב נספר אך לא ישיג הוא מצב בו המיקום הוא של החיישן, $carrying_sensor=0$, הוא נספר כחלק מהקומבינציות, אבל מהגדרות התרגיל הגעה לתא עם חיישן גוררת נשיאה שלו.

שאלה 2

a. $V_0(s) = 0$

$$V_t(s) = \max_a \sum_{s'} P(s'|a, s) (R(s, a, s') + V_{t-1}(s'))$$

- b. במקרה של מצב סופי s , $P(s'|a, s) = 1$ if $s = s'$, else 0. בנוסף, התגמול יהיה 0 לכל פעולה ומצב מתקבל. כך ניתן לדמות סופיות.
- c. $\pi_t(s) = \argmax_a \sum_{s'} P(s'|a, s) (R(s, a, s') + V_{t-1}(s'))$
- d. $\pi_0(s)$ אינו רלוונטי כי אין פעולה נוספת לעשות)
 כי ייתכן שעבור אותו המצב בדיוק, יהיה הבדל במדיניות עבור מספר שונה של צעדים עתידיים אפשריים – למשל במקרה של רווח גדול מאוד בעוד x צעדים (שבדרך אליו עונשים שסכומם גדול אבל קטן בהרבה מהרווח) – עבור מספר צעדים נותר גדול מ- x המדיניות תהיה אל עבר הרווח העתידי הזה, אבל עבור מספר צעדים קטן מ- x הרווח לעולם לא יגיע ולכן לא תבחר המדיניות הזו (בגלל הקנסות בדרך)

שאלה 3

- a. עבור safe: התועלת היא 2- (לא נגיע לרווח, ונפסיד נקודה בכל צעד). עבור risk: תוחלת התועלת היא $6 = 14 - 6 - 2 = 0.7 * 20 + 0.3 * -20 - 2$. לכן risk עדיף.
- b. עבור safe: התועלת היא $16 = 1 * 20 - 4$. עבור risk: תוחלת התועלת היא $0.7 * 20 + 0.3 * -20 - 2 = 6$. לכן safe עדיף.
- c. מדיניות סטציונרית מבטיחה את אותה המדיניות לכל מצב ללא תלות במספר הצעדים הנותר. ייצוג של המצב רק על פי המיקום, לא מסמן מהו מספר הצעדים הנותר, לכן מדיניות סטציונרית תקבע את אותה המדיניות בין אם נותרו 4 או 2 צעדים, זאת בניגוד לכך שראינו ההפעולה הטובה ביותר משתנה על פי כמות הצעדים הנותרים.

שאלה 4

a. $\hat{P}(u|s, up) = \frac{N(s, up, u) + \lambda}{N(s, up) + \lambda K} = \frac{6+1}{8+4} = \frac{7}{12}$

$$\hat{P}(r|s, up) = \frac{N(s, up, r) + \lambda}{N(s, up) + \lambda K} = \frac{2+1}{8+4} = \frac{3}{12}$$

$$\hat{P}(d|s, up) = \hat{P}(s|s, up) = \frac{0+1}{8+4} = \frac{1}{12}$$

b. $\hat{P}(r|s, right) = \frac{N(s, right, r) + \lambda}{N(s, right) + \lambda K} = \frac{1+1}{2+4} = \frac{2}{6}$

$$\hat{P}(d|s, right) = \frac{N(s, right, d) + \lambda}{N(s, right) + \lambda K} = \frac{1+1}{2+4} = \frac{2}{6}$$

$$\hat{P}(s|s, right) = \hat{P}(u|s, right) = \frac{0+1}{2+4} = \frac{1}{6}$$

- c. המודל לא אמין מכיוון שלא התבצעו שום תצפיות על wait ממצב s, ולכן אין דרך אמינה לשער מה תהיה התוצאה. המודל פשוט נותן את אותה ההסתברות לכל אחד מהמצבים.
- d. העריכו מודל ואז תכננו, בדומה ל ADP או למידה מבוססת מודל, מתבססות על כך שאנחנו לא מתעניינים רק בתוצאה אלא רוצים להבין כיצד פועל המודל עצמו, ועל פי זה לפעול.

שאלה 5

- a. הגדלת הקנס עשויה להפוך את המדיניות ל'זהירה' יותר. במקום בו יש סיכוי להצלחה אבל סיכוי מעט קטן יותר לתא מסוכן סופי, המדיניות ללא הגדלת הקנס עשויה להיות 'לקחת את הסיכון', בעוד לאחר הגדלת הקנס הסיכון נעשה גדול יותר וייתכן שיתועדפו אפשרויות אחרות.
- b. הכפלה בסקלר - כאשר כל התגמולים מוכפלים בסקלר זה אינו משפיע על המדיניות כלל.
- c. הוספת סקלר - למשל הוספה של 1- לכל תגמול, הופכת כל צעד רגיל ליקר פי 2, כאשר ההשפעה על הצלחה/תא מסוכן סופי היא זניחה יחסית, ובכך מעודדת מסלולים קצרים יותר.
- d. ייתכן שהמחיר בסיכון יהיה גדול בצורה קיצונית, אבל בהתאמה גם הסיכוי שלו יהיה קטן מאוד מאוד, ואז למרות שבתוחלת זהו מסלול מסוכן, בפועל במקרה הסביר נגיע להצלחה (למשל, אנחנו נוסעים ברכבים למרות שאם נסתכל על התוחלת כאשר תאונת דרכים היא אופציה יכול להיות שנגדיר את המסלול כמסוכן)

שאלה 6

- a. $V_{new}(s) = V(s) + \alpha(r + \gamma V(s') - V(s)) = 4 + 0.25(-2 + 0.9 * 7 - 4) = 4.075$
- b. $Q_{new}(s, a) = Q(s, a) + \alpha(r + \gamma \max_{a'} Q(s', a) - Q(s, a)) = 1 + 0.2(5 + 0.8 * 3 - 1) = 2.28$
- c. TD מחשב את הערך של הצומת על פי מהסלול הנתון. Q-learning מחשב את הערך של הצומת על בסיס המקסימום בין כל המסלולים האפשריים.
- d. ישנו סיכוי של 0.9 שנבחר בפעולה החמדנית, וסיכוי של 0.1 שנבחר אחת מהפעולות באופן אקראי. כלומר, הסיכוי שנבחר פעולה שאינה חמדנית **מסוימת** היא $0.02 = 0.1 * \frac{1}{5}$.
- e. אם האפסילון ידעך מהר מדי, הסיכוי לחקור מסלולים חדשים ירד מהר מדי, וינתקע על המסלול הקיים.

שאלה 7

- a. $V_{MC}(s_0) = \frac{1}{N_{s_0}} \left(\sum_{i=1}^{N_{s_0}} \sum_{t=0}^{T_i} r(s_t^i) \right) = \frac{1}{3} ((2 - 1 + 5) + (-2 + 4) + (1 + 1 + 1 + 1)) = \frac{1}{3} (6 + 2 + 4) = 4$
- b. מכיוון שמונטה קרלו מתבסס על התוצאה הסופית של כל מסלול סימולציה, בעוד TD מסתכל על התגמול המקומי יחד עם הערך שכבר ידוע לו על הצעד הבא
- c. בלמידה מבוססת מודל, ההערכה של פעולת המודל במצב s עם הפעולה a יהיה לקוי ולא אמין, וכתוצאה מכך ההערכה על פי המודל שהוערך תהיה לא מדויקת. ב Q-learning אנחנו מבססים את המדיניות על פי הפעולה שנותנת את הערך המקסימלי, ואם הפעולה a כמעט שלא נבחרה במצב s, כל הערכים המבוססים על מעבר ל s יהיו לא אמינים.
- d. אתחול כל הערכים הלא ידועים בערך אינסופי, כך שתעודד חקירה דווקא של הערכים שלא נחקרו עדיין (יכול לעבוד בסביבה טבלאית כי היא סופית ולכן לאחר מספר חקירות סופי לא יישארו ערכים אינסופיים בטבלה)

שאלה 8

- a. נחשב מרחק של q מכל אחת מהדוגמאות:

$$d(x_1, q) = \sqrt{2^2 + 1^2} = \sqrt{5}$$

$$d(x_2, q) = \sqrt{2^2 + 2^2} = \sqrt{8}$$

$$d(x_3, q) = \sqrt{30^2} = 30$$

$$d(x_4, q) = \sqrt{28^2 + 1^2}$$

השכן הקרוב ביותר הוא x_1 ולכן נסווג כnormal.

b. נמצא min-max עבור כל פיצ'ר, וננרמל:

smoke_density : max=70, min=12, max-min=58, ולכן המכנה בנרמול יהיה 58.

recent_slips : max=3, min=0, max-min=3, ולכן המכנה בנרמול יהיה 3.

כעת נציג את הערכים המנורמלים של הנקודות הנתונות:

$$x_1 = \left(\frac{26}{58}, 0\right), x_2 = \left(\frac{30}{58}, 1\right), x_3 = \left(1, \frac{1}{3}\right), x_4 = \left(0, \frac{2}{3}\right)$$

$$q = \left(\frac{28}{58}, \frac{1}{3}\right)$$

כעת נמצא את השכן הקרוב ביותר של q:

$$d(x_1, q) = \sqrt{\frac{2^2}{58} + \frac{1^2}{3}}$$

$$d(x_2, q) = \sqrt{\left(\frac{2}{58}\right)^2 + \left(\frac{2}{3}\right)^2} > d(x_1, q)$$

$$d(x_3, q) = \frac{30}{58} > d(x_1, q)$$

$$d(x_4, q) = \sqrt{\left(\frac{26}{58}\right)^2 + \left(\frac{1}{3}\right)^2} > d(x_1, q)$$

לכן שוב נסווג את q כnormal.

c. במידה שפיצ'ר א הוא במימדים גדולים בהרבה מפיצ'ר ב, פיצ'ר א משפיע יותר יחסית מפיצ'ר ב בבחירת השכן. לאחר נרמול, לשני הפיצ'רים השפעה דומה יחסית על בחירת השכן.

d. בבחירת K קטן מאוד אנחנו בוחרים לסווג כמו הדוגמה הקרובה ביותר, ללא התייחסות לשאר הנקודות בסביבה. בבחירת K גדול מאוד אנחנו מתייחסים לנקודות רבות בסביבה,

אבל נותנים את אותו משקל לנקודות קרובות יותר ופחות לנקודה שלנו.

e. ייתכן מקרה שבו מספר התוויות לא מאוזן, למשל יש הרבה יותר תוויות T מאשר F. מסווג

שיסווג תמיד T ישיג תוצאות טובות מאוד, אבל זה לא ערכי לנו כי אנחנו מחפשים מסווג

שיוכל להגיד לנו מתי דווקא F.