

תרגיל בית 3 - תהליכי החלטה מרקוביים ולמידה מחיזוקים

רובוט חילוץ תחת מגבלת זמן

מבוא לבינה מלאכותית 236501

אביב 2026

תאריך הגשה: 22.07.2026 אחראי התרגיל: נבו שניידר

הנחיות כלליות

- עברו על כלל ההנחיות לפני תחילת התרגיל. בתרגיל זה נעסוק בתהליכי החלטה מרקוביים ובלמידה מחיזוקים. התרגיל כולל חלק יבש, חלקים רטובים, והצהרת שימוש בכלי בינה מלאכותית.
- את המטלה יש להגיש בזוגות בלבד, אלא אם התקבל אישור מפורש מצוות הקורס.
- יש להגיש מטלות מוקלדות בלבד. פתרונות בכתב יד לא ייבדקו.
- ניתן לשלוח שאלות בנוגע לתרגיל בפיאצה בלבד.
- במהלך התרגיל ייתכן שנעלה עדכונים מחייבים בפיאצה. עליכם להתעדכן בהם עד מועד ההגשה.
- שימו לב: העתקות וטיפול לא תקין בשימוש בכלי עזר יטופלו בחומרה.
- לחלקים הרטובים מסופק שלד קוד. אין לשנות את חתימות הפונקציות הנדרשות.
- מותר להשתמש בספרייה הסטנדרטית של Python.
- מותר להשתמש גם ב-numpy, pandas ו-matplotlib. קוד שישתמש בספריות חיצוניות נוספות ללא אישור לא יתקבל.
- מומלץ לחזור על שקפי ההרצאות והתרגולים הרלוונטיים לפני תחילת העבודה.

חלק	נושא	נקודות
א	חלק יבש: תהליכי החלטה מרקוביים ולמידה מחיזוקים	45
ב	חלק רטוב: תכנון באופק סופי כאשר המודל ידוע	20
ג	חלק רטוב: למידה מחיזוקים כאשר המודל אינו ידוע	30
ד	הצהרת שימוש בכלי AI	5
סך הכל		100

חומר רלוונטי מהקורס

התרגיל מבוסס על החומר הבא:

- תרגולים 7-8: הגדרת תהליך החלטה מרקובי, תכונת מרקוב, אופק סופי ואינסופי, מדיניות, משוואות בלמן, value iteration, חילוץ מדיניות, הערכת מדיניות ו-policy iteration.
- תרגול 9 והרצאת למידה מחיזוקים: למידה פסיבית מול למידה אקטיבית, למידה מבוססת מודל מול למידה ללא מודל, Monte Carlo, TD(0), ADP, חקירה מול ניצול, ו-Q-learning.
- תרגולי למידה חישובית: חלוקה לאימון ובדיקה, אימות צולב, KNN, מדדי מרחק, נרמול מאפיינים, בחירת k , והשפעת מאפיינים בסקאלות שונות.
- אין צורך להשתמש ברשתות נוירונים, deep RL, MCTS, policy gradients, או חבילות חיצוניות לתכנון ולמידה. אם מופיעה טכניקה שלא הודגשה בתרגול, היא מוגדרת במפורש בגוף השאלה.

רקע: רובוט חילוץ תחת מגבלת זמן

בחלקים הרטובים נעבוד עם סביבת רובוט חילוץ אחת. רובוט קטן פועל במעבדה מלאה עשן. עליו לאסוף חיישן עדין ולהביא אותו ליציאה לפני שנגמרים לו הזמן או הסוללה. הסביבה היא לוח משבצות עם קירות, תאים רגילים, תאי סכנה, עמדות טעינה, מיקום איסוף החיישן, יציאות ותאים סופיים מסוכנים. מצב הרובוט בסביבה המסופקת מיוצג על ידי:

$state = (row, col, carrying_sensor, battery_level, time_remaining)$

הפעולות האפשריות הן:

UP, DOWN, LEFT, RIGHT, WAIT

מודל המעבר סטוכסטי. בתאים רגילים התנועה אמינה יחסית. בתאי עשן התנועה פחות אמינה. בתאים חלקים יש הסתברות גבוהה יותר לסטייה לצדדים. בתאים פגומים ייתכן איבוד סוללה נוסף. עמדת טעינה יכולה להעלות את רמת הסוללה, אך עדיין צורכת זמן. המשימה מסתיימת בהצלחה אם הרובוט מגיע ליציאה כאשר הוא נושא את החיישן ולפני מגבלת הזמן. המשימה נכשלת אם הסוללה מגיעה לאפס, אם הזמן נגמר, או אם הרובוט נכנס לתא סופי מסוכן.

[45 נק']

חלק א' - חלק יבש

יש לענות על חלק זה בדוח ה-PDF. הקפידו לנמק תשובות מילוליות ולהראות חישובים כאשר נדרש חישוב מספרי.

תזכורת מתרגולי תהליכי החלטה מרקוביים. מצב צריך להכיל את המידע הדרוש כדי לחזות את התפלגות המצב הבא ואת התגמול המיידי אחרי בחירת פעולה. כלומר, לאחר שיודעים את s ואת a , המודל משתמש ב- $P(s' | s, a)$ וב- $R(s, a, s')$, ולא אמור להזדקק לכל ההיסטוריה שהובילה אל s .

[6 נק']

שאלה 1 - ייצוג מצבים ותכונות מרקוב

נניח שבמפה מוקטנת יש 18 תאים שאינם קירות, תא איסוף אחד לחיישן, שתי יציאות ועמדת טעינה אחת. רמות הסוללה הן 0, 1, 2, 3, 4, 5, והדדליין הוא $H = 20$ צעדים.

(a) [2 נק'] הסבירו מדוע שימוש רק במיקום (row, col) כמצב מפר את תכונות מרקוב.

(b) [2 נק'] הגדירו ייצוג מצב שמחזיר את תכונות מרקוב.

(c) [1 נק'] חשבו חסם עליון נאיבי למספר המצבים המורחבים לפי הייצוג שהצעתם.

(d) [1 נק'] תנו דוגמה אחת למצב שנספר בחסם הנאיבי אך אינו ישים או אינו ניתן להגעה, והסבירו מדוע.

[6 נק']

שאלה 2 - משוואות בלמן לאופק סופי

נסמן ב- $V_t(s)$ את התוחלת המקסימלית של התועלת כאשר הסוכן נמצא במצב s ונשארו לו בדיוק t פעולות. התגמולים הם תגמולים תהליכיים $R(s, a, s')$, ומודל המעבר הוא $P(s' | s, a)$.

(a) [2 נק'] כתבו את נוסחת הרקורסיה של בלמן עבור $V_t(s)$, כולל תנאי הבסיס.

(b) [1 נק'] הסבירו כיצד יש לטפל במצבים סופיים.

(c) [2 נק'] הגדירו את המדיניות האופטימלית התלויה בזמן $\pi_t(s)$.

(d) [1 נק'] הסבירו מדוע באופק סופי המדיניות האופטימלית לא חייבת להיות סטציונרית.

[נק' 6]

שאלה 3 - מדיניות סטציונרית ולא סטציונרית

הרובוט נמצא בצומת J , וכבר נושא את החיישן. הוא יכול לבחור בין שתי פעולות:

- **SAFE**: הגעה ליציאה בדיוק אחרי 4 צעדים בהסתברות 1. תגמול $+20$ ביציאה, ועלות צעד -1 לכל פעולה.
- **RISKY**: הגעה ליציאה בדיוק אחרי 2 צעדים בהסתברות 0.7 , ונפילה לתא מסוכן סופי בהסתברות 0.3 . תגמול $+20$ בהצלחה, תגמול -20 בתא מסוכן, ועלות צעד -1 לכל פעולה.

בשאלה זו אין היוון.

- (a) [2 נק'] חשבו מהי הפעולה הראשונה הטובה יותר כאשר נשארים $t = 2$ צעדים.
- (b) [2 נק'] חשבו מהי הפעולה הראשונה הטובה יותר כאשר נשארים $t = 4$ צעדים.
- (c) [2 נק'] הסבירו מדוע מדיניות סטציונרית שתלויה רק במיקום הפיזי J אינה יכולה לייצג את שתי התשובות.

[נק' 5]

שאלה 4 - הערכת מודל מעבר מדגימות

עבור מצב לא סופי s , מדיניות התנהגות כלשהי יצרה את התצפיות הבאות:

תגמול ממוצע	ספירה	מצב הבא	פעולה	מצב
1-	6	u	UP	s
3-	2	r	UP	s
1-	1	r	RIGHT	s
10-	1	d	RIGHT	s
–	0	s	WAIT	s

נניח שלצורך החלקת לפלס קבוצת המצבים הבאים האפשריים היא $\{u, r, d, s\}$, ולכן $K = 4$. השתמשו בכלל:

$$\hat{P}(s' | s, a) = \frac{N(s, a, s') + \lambda}{N(s, a) + \lambda K}.$$

- (a) [2 נק'] חשבו את $\hat{P}(\cdot | s, \text{UP})$ עבור $\lambda = 1$.
- (b) [1 נק'] חשבו את $\hat{P}(\cdot | s, \text{RIGHT})$ עבור $\lambda = 1$.
- (c) [1 נק'] הסבירו מדוע תכנון לפי המודל המוערך עבור WAIT אינו אמין.
- (d) [1 נק'] קשרו בקצרה בין גישת "העריכו מודל ואז תכננו" לבין ADP או למידה מבוססת מודל.

[נק' 5]

שאלה 5 - תגמולים ומדיניות אופטימלית

שני מתרגלים מציעים שתי פונקציות תגמול לאותה סביבת חילוך:

תא מסוכן סופי	צעד רגיל	הצלחה	הגדרה
-50	-1	+50	בסיסית
-200	-1	+50	מחמירה בסכנות

- (a) [2 נק'] הסבירו כיצד הגדלת הקנס על סכנות יכולה לשנות את המדיניות האופטימלית.
- (b) [1 נק'] ציינו טרנספורמציה אחת על כל התגמולים ששומרת על כל המדיניות האופטימליות.
- (c) [1 נק'] ציינו שינוי אחד בתגמולים שלא חייב לשמור על המדיניות האופטימלית.
- (d) [1 נק'] הסבירו מדוע גם תחת תוחלת תועלת רגילה ייתכן שמסלול מסוכן יהיה עדיף אם הסתברות ההצלחה שלו מספיק גבוהה.

שאלה 6 - עדכון הפרש זמני, עדכון Q-learning וחקירה [6 נק']

(a) [2 נק'] מדיניות קבועה יצרה מעבר מדגם $s \rightarrow s'$ עם תגמול $r = -2$. נתון $V(s) = 4, V(s') = 7$, $\alpha = 0.25, \gamma = 0.9$. בצעו עדכון TD(0) אחד עבור $V(s)$.

(b) [1 נק'] סוכן Q-learning צפה ב- (s, a, r, s') עם $r = 5$. נתון $Q(s, a) = 1, Q(s', a') = 3, \max_{a'} Q(s', a') = 3, \alpha = 0.2$. בצעו עדכון אחד עבור $Q(s, a)$. $\gamma = 0.8$.

(c) [1 נק'] הסבירו את ההבדל בין הערכת מדיניות קבועה בעזרת TD לבין למידת בקרה בעזרת Q-learning.

(d) [1 נק'] ב-greedy- ϵ עם $\epsilon = 0.1$ וחמש פעולות חוקיות, מה ההסתברות לבחור פעולה מסוימת שאינה חמדנית, בהנחה שיש פעולה חמדנית יחידה?

(e) [1 נק'] הסבירו מדוע לא כדאי ש- ϵ ב-greedy ידעך מהר מדי.

שאלה 7 - אומדן Monte Carlo, למידת TD והטיית מדגם [5 נק']

נרצה להעריך את $V^\pi(s_0)$ עבור מדיניות קבועה π . נאספו שלושה פרקים המתחילים ב- s_0 . המספרים הם תגמולים לאחר כל צעד, ואין היוון בשאלה זו.

פרק	רצף תגמולים
1	+2, -1, +5
2	-2, +4
3	+1, +1, +1, +1

(a) [2 נק'] חשבו אומדן first-visit Monte Carlo עבור $V^\pi(s_0)$.

(b) [1 נק'] הסבירו מדוע אומדן Monte Carlo מחכה לסוף הפרק, ואילו TD(0) יכול להתעדכן אחרי צעד אחד.

(c) [1 נק'] נניח שהמדיניות שאספה את הדגימות כמעט אף פעם לא בוחרת פעולה מסוימת a במצב s . הסבירו כיצד הדבר יכול לפגוע גם בלמידה מבוססת מודל וגם ב-Q-learning.

(d) [1 נק'] הציעו דרך אחת פשוטה להגדיל חקירה בסביבה טבלאית.

שאלה 8 - KNN, נרמול מאפיינים ועלות החלטה [6 נק']

בטבלה הבאה יש מאגר אימון קטן עם שני מאפיינים: smoke_density בסקאלה 0-100, ו-recent_slips בסקאלה 0-3. נקודת השאילתה היא $q = (40, 1)$.

תווית	recent_slips	smoke_density	דוגמה
normal	0	38	x_1
slippery	3	42	x_2
smoky	1	70	x_3
normal	2	12	x_4

(a) [1 נק'] סווגו את q בעזרת 1-NN עם מרחק אוקלידי וללא נרמול.

(b) [2 נק'] נרמלו כל מאפיין בעזרת min-max לפי ארבע דוגמאות האימון, וסווגו שוב את q בעזרת 1-NN.

(c) [1 נק'] הסבירו מדוע נרמול יכול לשנות את השכן הקרוב ביותר.

(d) [1 נק'] הסבירו את ההבדל בין בחירת k קטן מאוד לבין בחירת k גדול מאוד.

(e) [1 נק'] תנו סיבה אחת לכך שדיוק סיווג גבוה עדיין לא מבטיח ביצועי חילוף טובים.

[20 נק']

חלק ב' - רטוב: תכנון באופק סופי כאשר המודל ידוע

בחלק זה מודל הסביבה ידוע במלואו, כפי שהיה בתרגולי התכנון. שלד הקוד יספק טעינת מפות, בניית מצבים, חישוב תגמולים, סימולציה וויזואליזציה.

קבצים מסופקים

```
code/
  rescue_env.py
  rescue_types.py
  visualize.py
  tests_public.py
data/
  rescue_map.csv
  hazard_map_known.csv
  rescue_config.json
```

הסביבה חושפת את הממשק הבא:

```
env.initial_state()
env.is_terminal(state)
env.actions(state)
env.transitions(state, action) # List of (probability, next_state, reward)
env.reachable_states(horizon)
env.simulate(policy, horizon, seed)
```

בנוסף, הקובץ `visualize.py` כולל פונקציות עזר ליצירת איורים של המפה, פרוסות מדיניות ומסלולי סימולציה:

```
plot_map(env)
plot_policy_slice(env, policy, time_remaining, carrying=False, battery=None)
save_policy_slice(env, policy, output_path, time_remaining,
                  carrying=False, battery=None)
animate_trajectory(env, trajectory, output_path=None)
```

קובץ להגשה

יש להגיש את הקובץ:

`planning_rescue.py`

פונקציות למימוש

```
def finite_horizon_dp(env, horizon):
    """Return V[t][s] and a time-dependent policy pi[t][s]."""

def action_value(env, V_next, state, action):
    """Return the one-step expected backup for a specific action."""

def rollout_time_dependent_policy(env, policy, n_episodes, seed):
    """Simulate a time-dependent policy and return mission statistics."""

def compare_policy_slices(env, policy, states_to_show):
    """Return a table showing how actions change with time or battery."""
```

אם לשתי פעולות יש בדיוק אותו ערך, בחרו את הפעולה שמופיעה מוקדם יותר בסדר שמוחזר על ידי `env.actions(state)`. כלל זה נועד להפוך את הבדיקות לדטרמיניסטיות.

ניסויים ודוח

השתמשו במפה ובקונפיגורציה המסופקות. אם לא נאמר אחרת, השתמשו ב-`seed=236501`.

1. **[4 נק']** הריצו תכנון באופק סופי עבור $H \in \{12, 20, 30\}$. דווחו את ערך המצב ההתחלתי ואת מספר המצבים הנגישים בכל אופק.
2. **[4 נק']** העריכו כל מדיניות בעזרת 100 סימולציות. דווחו שיעור הצלחה, תגמול כולל ממוצע, אורך פרק ממוצע ופירוט כשלונות.
3. **[4 נק']** הציגו לפחות שלושה מצבים שבהם הפעולה האופטימלית משתנה כאשר הזמן שנותר או רמת הסוללה משתנים.
4. **[4 נק']** השוו בין תגמולי הבסיס לבין הגדרה שבה תגמולי התאים המסוכנים מוכפלים ב-4. דווחו האם המדיניות והסטטיסטיקות השתנו. אם השינוי קטן או לא קיים, הסבירו זאת בעזרת פירוט סוגי הכשלונות והמצבים שבהם המדיניות כן השתנתה.
5. **[4 נק']** צרפו לדוח ויזואליזציה של המדיניות עבור לפחות שתי פרוסות מצב משמעותיות. בכל ויזואליזציה ציינו את t , האם הרובוט נושא את החיישן, ורמת הסוללה. למשל, ניתן לבחור פרוסה עם $t = 5$, נשיאת חיישן ורמת סוללה 2, ופרוסה עם $t = 15$, ללא חיישן ורמת סוללה 1.

חלק ג' - רטוב: למידה מחיזוקים כאשר המודל אינו ידוע **[30 נק']**

בחלק זה הרובוט אינו מקבל את הסתברויות המעבר האמיתיות. זהו המעבר מתכנון עם מודל נתון ללמידה מחיזוקים מתוך ניסיון. הרובוט ילמד גם ממסלולים מוקלטים מראש וגם מאינטראקציה עם הסימולטור.

קבצים מסופקים

```
data/
  offline_rollouts_sparse_train.jsonl
  offline_rollouts_sparse_validation.jsonl
  offline_rollouts_good_train.jsonl
  offline_rollouts_good_validation.jsonl
```

כל רשומה במסלולים מכילה:

```
state, action, reward, next_state, done
```

הקבצים ששמן כולל `sparse` הם בכוונה נתוני חקירה דלים: הם כמעט לא מכסים את המסלול הטוב, ולכן הם משמשים דוגמה שלילית להשפעת כיסוי נתונים חלש. לעומתם, הקבצים ששמן כולל `good` נאספו ממדיניות טובה יותר וכוללים גם מסלולי הצלחה. השתמשו בהם כבדיקת שפיות שמראה כיצד מודל מוערך משתפר כאשר יש בנתונים אות תגמול חיובי.

קובץ להגשה

יש להגיש את הקובץ:

`learning_rescue.py`

פונקציות למימוש

```
def estimate_transition_reward_model(trajectories, actions, smoothing):
    """Estimate P_hat and R_hat from offline trajectories."""

def plan_with_estimated_model(model, start_state, horizon):
    """Run finite-horizon planning on the learned model."""

def first_visit_mc(env, policy, n_episodes, gamma, seed):
    """Estimate V^pi from sampled episodes."""

def td_prediction(env, policy, n_episodes, alpha_schedule, gamma, seed):
    """Estimate V^pi from online interaction."""

def q_learning_rescue(env, n_episodes, alpha_schedule,
                      epsilon_schedule, gamma, seed):
    """Learn a tabular Q policy with epsilon-greedy exploration."""

def boltzmann_action(Q, state, actions, temperature):
    """Sample an action according to softmax(Q(state, action) / temperature)."""

def evaluate_rescue_agent(env, policy, n_episodes, seed):
    """Return success rate, mean return, mean length, and failure breakdown."""
```

מפת האלגוריתמים בחלק הרטוב

כדי למנוע בלבול בין השיטות, השתמשו בהבחנה הבאה לאורך כל החלק הרטוב:

- **מתכנן עם המודל האמיתי, או מתכנן אורקל:** האלגוריתם מחלק ב'. הוא משתמש ישירות במעברי הסביבה האמיתיים, דרך `env.transitions`, ולכן יודע את הסתברויות המעבר והתגמולים האמיתיים. זהו קו בסיס להשוואה, ולא שיטת למידה מנתונים.
 - **למידת מודל מעבר ותגמול:** הפונקציה `estimate_transition_reward_model`. זו אינה מדיניות פעולה בפני עצמה. היא מקבלת מסלולים מוקלטים ומחזירה מודל מוערך של מעברים ותגמולים.
 - **מתכנן לפי מודל מוערך:** הפונקציה `plan_with_estimated_model`. היא מקבלת את המודל שנלמד מהנתונים, מתכננת בתוכו, ומחזירה מדיניות. לאחר מכן מעריכים את המדיניות הזאת בסימולטור האמיתי.
 - **Monte Carlo ו-TD(0):** אלו אומדי ערך למדיניות קבועה. בחלק זה הם לא לומדים מדיניות חדשה ולא בוחרים פעולות כדי לפתור את המשימה; הם מעריכים V^π עבור אותה מדיניות מחלק ב'.
 - **סוכן בקרה ללא מודל:** Q-learning לא בונה טבלת הסתברויות מעבר. הוא לומד ערכי פעולה מאינטראקציה ומפיק מהם מדיניות חמדנית בסוף האימון.
 - **חקירת Boltzmann:** כלל לבחירת פעולות בזמן למידה לפי ערכי Q . זו דרך אחרת לבצע חקירה, לא אלגוריתם נפרד להערכת מדיניות ולא מודל מעבר.
- הפונקציה `estimate_transition_reward_model` חייבת להחזיר מילון במבנה הבא, כדי שהקוד שלכם והבדיקות ידברו באותו ממשק:

```
{
  "transitions": {
    (state, action): [(probability, next_state, mean_reward), ...],
    ...
  },
  "actions_by_state": {
    state: (action1, action2, ...),
    ...
  },
  "states": (state1, state2, ...),
  "actions": actions,
}
```

- עבור כל שלשה $(state, action, next_state)$ השתמשו בתגמול הממוצע שנצפה עבורה.
- אין להמציא מעברים עבור פעולות או מצבים שלא נצפו בנתונים.
- בתכנון לפי מודל מוערך, מצב שאין לו פעולות ב-`actions_by_state` ייחשב מצב סופי עם ערך 0.
- בשוויון מדויק בין פעולות, שברו את השוויון לפי סדר הפעולות ב-`model["actions"]`.
- אם במהלך הערכה בסימולטור האמיתי המדיניות שנלמדה אינה מכילה פעולה עבור מצב שהרובוט הגיע אליו, הסביבה תבחר את הפעולה החוקית הראשונה לפי `env.actions(state)`. בדוח ציינו אם מדיניות מסוימת הסתמכה על כלל גיבוי זה לעיתים קרובות.

הגדרות מחייבות

מספרי הפרקים להלן נבחרו כך שהניסויים ירוצו בזמן סביר על מחשב אישי רגיל. אין צורך להריץ אלפי פרקים מעבר למה שמוגדר כאן, אלא אם אתם רוצים לבדוק יציבות נוספת של הגרפים או של המסקנות. השתמשו באופק הפרק שמוגדר ב-`rescue_config.json`. עבור TD ו-Q-learning, השתמשו בקצב הלמידה הבא:

$$\alpha_t = \frac{0.5}{1 + \lfloor t/1000 \rfloor}.$$

עבור Q-learning, השוו בין שני כללים לבחירת הסתברות החקירה ϵ . שימו לב: אלו כללים להסתברות בחירת פעולה שאינה חמדנית, ולא שינוי בתגמולים של הסביבה.

$$\epsilon_t = 0.1 \quad \text{or} \quad \epsilon_t = \max(0.02, 1/\sqrt{t+1}).$$

ניסויים ודוח

שימו לב להבחנה בין סוגי השיטות: מתכנן האורקל, המתכנן לפי מודל מוערך ו-Q-learning הם סוכני קבלת החלטות שמייצרים מדיניות לפעולה. לעומת זאת, Monte Carlo ו-TD(0) בסעיף זה משמשים לאמידת ערך של אותה מדיניות קבועה, ולכן יש להשוות ביניהם כאומדי ערך ולא כסוכנים נפרדים שמנסים לפתור את משימת החילוץ.

1. [4 נק'] למדו מודל מעבר ותגמול מתוך קובץ האימון `offline_rollouts_sparse_train.jsonl`. הריצו את האמידה עבור שלושה ערכי החלקה: אפס, עשירית, ואחד.
2. [4 נק'] תכננו בכל מודל מוערך, והעריכו את המדיניות המתקבלת בסימולטור האמיתי. השוו למתכנן עם המודל האמיתי מחלק ב'. לאחר מכן חזרו על אותה בדיקה עם `offline_rollouts_good_train.jsonl`, והסבירו בקצרה כיצד איכות הנתונים משפיעה על המדיניות ועל שיעור ההצלחה.
3. [4 נק'] הריצו first-visit Monte Carlo עבור מדיניות קבועה מחלק ב' במשך 400 פרקים. השוו את הערכים המוערכים לערכים מחלק ב' עבור לפחות חמישה מצבים שנצפו במספר סביר של פרקים, וציינו כמה ביקורים היו לכל מצב.
4. [4 נק'] הריצו TD(0) עבור אותה מדיניות קבועה במשך 400 פרקים. השוו ל-Monte Carlo ולערכים המדויקים מחלק ב' עבור אותה קבוצת מצבים.
5. [4 נק'] הריצו Q-learning במשך 1000 פרקים עבור שני כללי ϵ שהוגדרו למעלה. העריכו את המדיניות הגרידית הסופית בעזרת 150 פרקי הערכה ללא המשך למידה.
6. [3 נק'] מימשו חקירת Boltzmann לפי הנוסחה:

$$P(a | s) = \frac{\exp(Q(s, a)/T)}{\sum_{b \in A(s)} \exp(Q(s, b)/T)}.$$

השוו בין $T = 1.0$ לבין $T = 0.2$, או בין שתי סדרות טמפרטורה שיפורסמו על ידי צוות הקורס. השתמשו באותם מספרי פרקי אימון והערכה שנדרשו עבור Q-learning.

7. [4 נק'] השוו בין שלושה סוכני קבלת החלטות: מתכנן אורקל מחלק ב', מתכנן לפי מודל מוערך, וסוכן Q-learning. עבור כל סוכן דווחו שיעור הצלחה, תגמול כולל ממוצע, אורך פרק ממוצע ופירוט כשלונות. בנוסף, השוו בקצרה בין Monte Carlo לבין TD(0) כאומדי ערך עבור אותה מדיניות קבועה: ציינו אילו מצבים הוערכו טוב יותר או פחות, והאם ההבדלים מתאימים לאופי הדגימות שראיתם.

8. [3 נק'] תארו כשל אחד שנגרם מחוסר חקירה בנתונים או בלמידה המקוונת. בתשובה התייחסו לפחות למצב אחד ולפעולה אחת שלא נצפו מספיק, והסבירו כיצד הדבר פגע במודל המוערך או במדיניות שנלמדה. עבור כל שיטה שהשוויתם, ציינו האם היא מבוססת מודל או ללא מודל, והאם היא פסיבית או אקטיבית.

[5 נק']

חלק ד' - הצהרת שימוש בכלי AI

כפי שפורט במסמך המדיניות, אנו רואים חשיבות מרכזית בפיתוח חשיבה ביקורתית ובשימוש רפלקטיבי בכלי AI. אנו מצפים כי השימוש שתבצעו יהיה לצורך העצמת הלמידה והבנייה המעמיקה של הידע, ולא לצורך העתקה עיוורת או הימנעות ממאמץ קוגניטיבי. בהמשך לכך, בשאלה זו תצטרכו לציין באילו כלי AI השתמשתם, ולפרט בהרחבה כיצד השתמשתם בהם בכל אחד מחלקי התרגיל:

(a) [2.5 נק'] בחלק התיאורטי, כלומר בחלק היבש.

(b) [2.5 נק'] בחלק המעשי, כלומר בחלק הרטוב.

מומלץ להסתכל במסמך המדיניות על דוגמאות לרמת הפירוט הנדרשת. בנוסף, בחלק זה, אנו מזמינים אתכם לצרף כנספח את השיחה שלכם עם כלי ה-AI בנוגע לפתרון שיעורי הבית. **שימו לב:** סטודנטים שרמת הפירוט שלהם בשאלה זו תהיה לא משכנעת מספיק, ו/או שלא צירפו את השיחה שלהם עם כלי ה-AI שאיתו עבדו, יוכלו להיבחר בצורה מדגמית לבחינה קצרה בעל פה על הגיליון והקוד שהגישו. אם לא השתמשתם בכלי AI, כתבו זאת במפורש והסבירו בקצרה כיצד בדקתם את עבודתכם באופן עצמאי.

רשימת הגשה

יש להגיש:

- AI_HW3.pdf - תשובות יבשות, גרפים, טבלאות ודיונים.
- planning_rescue.py
- learning_rescue.py
- קבצי עזר קטנים שכתבתם, אם הם נדרשים להרצת הקוד.
- בדוח חייבים להופיע:
 - תשובות מלאות לחלק היבש;
 - תוצאות תכנון לכל האופקים המבוקשים;
 - לפחות שתי ויזואליזציות של מדיניות;
 - תוצאות תכנון לפי מודל מוערך עבור הנתונים הדלים ועבור נתוני הכיסוי הטוב;
 - השוואה בין Monte Carlo, TD(0) ו-Q-learning;
 - דיון בחקירה מול ניצול;
 - הצהרת שימוש בכלי AI, ובמידת הצורך נספח עם השיחה שנערכה עם כלי ה-AI.

בדיקות פומביות וחביות

הבדיקות הפומביות נועדו לתפוס שגיאות בסיסיות, ולא להוכיח שהפתרון כולו נכון. הבדיקות החביות עשויות להשתמש בסביבות קטנות ובנתונים שונים. אין להקשיח בקוד ממדי מפה, סדר מצבים, תוצאות אקראיות, או תשובות שמתאימות רק לבדיקות הפומביות.